

Национальный исследовательский университет
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»
Факультет экономических наук

Курсовая работа

Прогнозирование временных рядов
с помощью модели состояние-наблюдение

Выполнила
студентка группы БЭК 151
Гнилова О.А.

Научный руководитель
старший преподаватель
департамента прикладной экономики
Демешев Б.Б.

Москва, 2017.

Содержание

1	Введение	2
2	Описание данных	3
3	Построение моделей одномерных рядов	6
3.1	Моделирование ошибкой – Irregular	6
3.2	Моделирование константой – Deterministic constant	11
3.3	Модель локального уровня – Local level	12
3.4	Случайное блуждание – Random walk	14
3.5	Постоянный тренд – Deterministic trend	16
3.6	Локальный линейный постоянный тренд – Local linear deterministic trend	17
3.7	Случайное блуждание со смещением – Random walk with drift	18
3.8	Локальный линейный тренд – Local linear trend	19
3.9	Сглаженный тренд – Smoothed trend	20
3.10	Случайный тренд – Random trend	21
3.11	Локальный линейный тренд с сезонностью	21
3.12	Локальный линейный тренд с сезонностью и регрессорами	24
4	Построение модели многомерных рядов	27
4.1	Описание модели	27
4.2	Пример: модель локального линейного уровня с регрессорами	27
4.3	Общие уровни и наклоны	29
5	Заключение	30
6	Список источников	31

1 Введение

В данной работе исследуется модель наблюдение-состояние (state space model), используемая в прогнозировании временных рядов. Её суть состоит в представлении наблюдаемого временного ряда в виде нескольких ненаблюдаемых компонент: тренда, сезонности и ошибки наблюдений, каждая из которых, в свою очередь, может моделироваться не единственным образом. Как правило, в модели предполагается ещё одна составляющая – цикличность, однако из-за специфики выбранных мною данных она рассмотрена не будет.

Цель работы – подробно описать возможные способы моделирования временного ряда, начиная с простых прогнозов, когда в уравнение наблюдаемой компоненты входит только погрешность наблюдений, до более сложных, когда в модель входят все перечисленные ненаблюдаемые компоненты и регрессоры, и реализовать их на языке Python с использованием библиотеки `statsmodels`. Также в работе описана модель локального линейного тренда с регрессорами в форме состояние-наблюдение для случая многомерных временных рядов.

2 Описание данных

Временные ряды для этой работы были взяты из соревнования [Rossmann Store Sales](#) на Kaggle и содержат информацию по продажам 1115 магазинов сети Rossmann за период 01-01-2013 по 31-07-2015, то есть за два с половиной года. Поскольку наиболее подробно мною изучались модели прогнозирования одномерных временных рядов, подопытным рядом стали продажи магазина с `id=1`. Посмотрим, как он выглядит:

```
In [1]: import pandas as pd
import matplotlib.pyplot as plt
%matplotlib inline

data = pd.read_csv('train.csv')
data.index = pd.to_datetime(data.Date)
data[data.Store==1].sort_values('Date').Sales.plot(marker='.',
                                                    figsize=(20,6))

plt.title('Rossmann Sales, Store 1')
plt.ylabel('Sales')
```

```
Out[1]: <matplotlib.text.Text at 0x1115185f8>
```

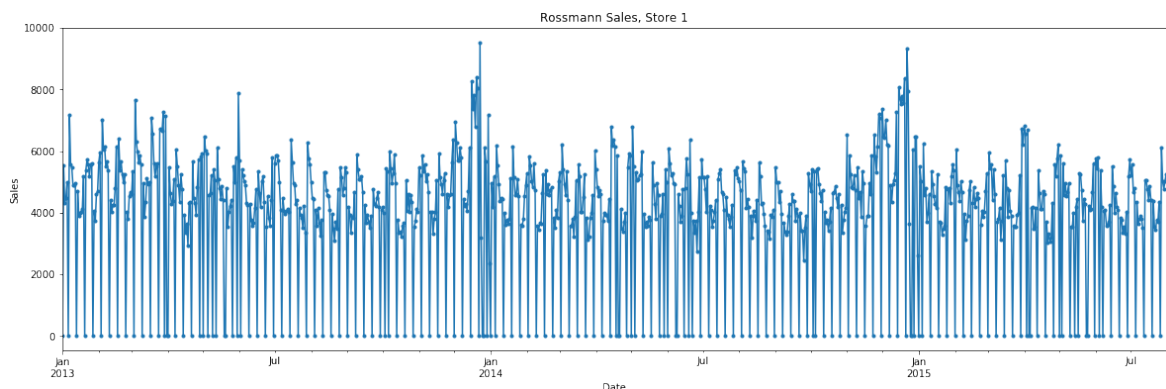


Рис. 1: Продажи в магазине 1

Из-за выходных и праздников, когда магазин закрыт и продаж нет, график выглядит очень зашумлённым. Более того, эти выбросы сильно влияют на результаты моделей, описанных мной далее, делают их менее наглядными. По этой причине я решила на время убрать нулевые значения из ряда, тем более, что они подчиняются понятному паттерну и их легко можно будет восстановить. Однако убрав их, я всё же не стану сохранять исходную последовательность дат, поскольку мне важны качественные результаты моделей, а не сами предсказанные значения. Работать же с исходной последовательностью дат не получается из-за того, что библиотека `statsmodels` не может давать прогноз на будущее для «необычных» дат: функция `get_forecast` не берёт

аргумент `freq`, задающий периодичность дней, которая здесь нестандартна: исключается каждое седьмое значение (те, что соответствуют воскресеньям), а также праздники.

Осуществим задуманное и посмотрим на график снова:

```
In [2]: dta = data[(data.Store==1)
                & (data.Open==1)].sort_values('Date').Sales

fig, ax = plt.subplots(figsize=(18,4))

ax.plot(dta)
ax.set_xlabel('Date')
ax.set_ylabel('Sales')
ax.set_title('Rossmann Sales, Store 1')
```

```
Out[2]: <matplotlib.text.Text at 0x112c54828>
```




Рис. 2: Ненулевые продажи в магазине 1

Теперь, когда ряд стал выглядеть лучше, можно сделать первые выводы о нём: в данных нет явного тренда, в декабре каждого года продажи резко увеличиваются, а амплитуда колебаний приблизительно постоянна.

Предположения о тренде и колебаниях можно сразу проверить: для этого необходимо установить, является ли ряд стационарным. Ответ будет положительным, если ни математическое ожидание, ни дисперсия его не зависят от времени. Проверка осуществляется с помощью теста Дики-Фулера, в котором нулевая гипотеза соответствует предположению о том, что ряд не стационарен.

```
In [3]: import statsmodels.api as sm

result = sm.tsa.stattools.adfuller(dta)
print('ADF Statistic: %f' % result[0])
print('p-value: %f' % result[1])
print('Critical Values:')
for key, value in result[4].items():
    print('\t%s: %.3f' % (key, value))
```

ADF Statistic: -5.399623
p-value: 0.000003
Critical Values:
10%: -2.569
5%: -2.865
1%: -3.439

Выходит, что на любом разумном уровне значимости гипотеза отвергается, а значит, ряд является стационарным. И теперь, когда про ряд стало известно больше, можно переходить к построению моделей.

3 Построение моделей одномерных рядов

Под моделью временного ряда для наблюдений $\{y_t\}$ будем понимать описание совместных распределений последовательности случайных величин $\{Y_t\}$, которые принимают значения $\{y_t\}$

3.1 Моделирование ошибкой – Irregular

Самая простая модель для прогнозирования временных рядов: в ней нет ни тренда, ни сезонности, а наблюдения считаются независимыми одинаково распределёнными случайными величинами Y_1, Y_2, \dots с нулевым математическим ожиданием:

$$y_t = \varepsilon_t$$
$$\varepsilon_t \text{ iid: } \varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2)$$

Выясним, какой прогноз будет давать эта модель. По определению, можем записать:

$$P[Y_1 \leq y_1, \dots, Y_n \leq y_n] = P[Y_1 \leq y_1] \cdot \dots \cdot P[Y_n \leq y_n] = F(y_1) \cdot \dots \cdot F(y_n)$$

где $F(\cdot)$ – функция распределения случайных величин Y_1, Y_2, \dots . Поскольку в модели предполагается, что наблюдения независимы, то для всех $h \geq 1$ и для всех y_1, \dots, y_n :

$$P[Y_{n+h} \leq y \mid Y_1 = y_1, \dots, Y_n = y_n] = P[Y_{n+h} \leq y]$$

Другими словами, предыдущие наблюдения не несут никакой информации о следующем наблюдении Y_{n+h} . При известных значениях Y_1, Y_2, \dots функция f , которая минимизирует среднеквадратичную ошибку $E[(Y_{n+h} - f(Y_1, \dots, Y_n))^2]$, равна нулю, покажем:

$$\begin{aligned} E[(Y_{n+h} - f(Y_1, \dots, Y_n))^2] &= E[Y_{n+h}^2 - 2 \cdot Y_{n+h} \cdot f(Y_1, \dots, Y_n) + f(Y_1, \dots, Y_n)^2] = \\ &= E[Y_{n+h}^2] - 2 \cdot f(Y_1, \dots, Y_n) \cdot E[Y_{n+h}] + f(Y_1, \dots, Y_n)^2 \rightarrow \min_f \end{aligned}$$

Так как $Y_{n+h} \sim \mathcal{N}(0, \sigma_\varepsilon^2)$, то $E[Y_{n+h}] = 0$ и задача сводится к минимизации следующей функции: $E[Y_{n+h}^2] + f(Y_1, \dots, Y_n)^2 \rightarrow \min_f$, а её минимум достигается, очевидно, при $f(Y_1, \dots, Y_n) = 0$.

Обучим модель и убедимся в том, что она будет давать только нулевые значения. В модуле `UnobservedComponents` библиотеки `statsmodels` необходимо указать все параметры модели: в данном примере единственным параметром является ошибка, поэтому прописываем аргумент `irregular=True`. Остальные модели можно настраивать схожим образом, или же передавать параметру `level` сокращённое назва-

ние модели, указанное в [документации](#). В таком случае все остальные параметры изменятся на нужные автоматически, в чём можно будет убедиться, вызвав функцию `model_name.fit().specification`.

```
In [4]: model_1 = statsmodels.tsa.statespace.structural. \
        UnobservedComponents(endog=dta, level=False,
                               trend=False, seasonal=None,
                               cycle=False, autoregressive=None,
                               exog=None, irregular=True,
                               stochastic_level=False,
                               stochastic_trend=False,
                               stochastic_seasonal=False,
                               stochastic_cycle=False,
                               damped_cycle=False,
                               cycle_period_bounds=None)
```

Выведем результаты модели:

```
In [5]: res_model_1 = model_1.fit()
        res_model_1.summary()
```

Out[5]: Unobserved components results

Dep. Variable:	Sales	No. Observations:	781
Model:	irregular	Log Likelihood	−7739
Date:	Sun, 21 May 2017	AIC	15480
Time:	14:11:26	BIC	15485
Sample:	01-01-2013	HQIC	15482
	- 02-20-2015		
Covariance Type:	opg		

Таблица 1: Описание модели Irregular

	coef	std err	z	P> z 	[0.025	0.975]
sigma2.irregular	$2.30 \cdot 10^7$	$3.53 \cdot 10^6$	6.52	0	$1.61 \cdot 10^7$	$2.99 \cdot 10^7$

Таблица 2: Оценка параметров модели Irregular

Ljung-Box (Q):	1255	Jarque-Bera (JB):	190.5
Prob(Q):	0.00	Prob(JB):	0.00
Heteroskedasticity (H):	0.98	Skew:	0.93
Prob(H) (two-sided):	0.88	Kurtosis:	4.54

Таблица 3: Информация о данных в модели Irregular

Как видно из таблиц, библиотека `statsmodels` выдаёт очень подробную информацию о модели. В частности, таблица 1 позволяет определять качество модели и сравнивать их между собой. AIC – информационный критерий Акаике – устроен на основе функции максимального правдоподобия и записывается следующим образом:

$$AIC = 2k - 2 \ln(L)$$

где k – количество параметров в модели, а L – максимум функции правдоподобия. Критерий вознаграждает за сходство результатов с истинными данными и штрафует за большое количество параметров, так что чем меньше его значение, тем модель лучше.

BIC – байесовский информационный критерий – модификация предыдущего критерия, основанная на байесовском подходе:

$$BIC = k \ln n - 2 \ln(L)$$

где n – объём выборки, а остальные параметры те же. Этот критерий сильнее штрафует за большое количество параметров.

И последний подсчитываемый критерий HQIC – это информационный критерий Ханнана-Куинна.

$$HQIC = 2k \ln \ln n/n - 2 \ln(L)/n$$

В таблице 3 находится информация о случайности данных. Так, в ней есть значение статистики Q-теста Льюнг-Бокса, формула для которого имеет вид:

$$\tilde{Q} = n(n+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{n-k} \sim \chi_m^2$$

где n – число наблюдений, $\hat{\rho}_k^2$ – автокорреляция k -ого порядка, m – количество лагов. В основной гипотезе предполагается, что данные являются случайными (белым шумом).

В таблице также представлены результаты теста Харке-Бера, который проверяет ошибки наблюдений на нормальность, сравнивая выборочные третий (S от skew, асимметрия) и четвёртый (K от kurtosis, эксцесс) моменты с соответствующими моментами нормального распределения, для которого $S = 0$, $K = 3$. Нулевая гипотеза в тесте так и формулируется: $\mathcal{H}_0 : S = 0, K = 3$, а статистика имеет вид:

$$JB = n \left(\frac{S^2}{6} + \frac{(K-3)^2}{24} \right) \sim \chi_2^2$$

где $S = \frac{\sum e_i^3}{n \hat{\sigma}_{ML}^3}$, $K = \frac{\sum e_i^4}{\hat{\sigma}_{ML}^4}$, e_i – остатки модели, n – количество наблюдений, $\hat{\sigma}_{ML}^2 =$

$\frac{\sum e_i^2}{n}$. Чем ближе значение статистики к нулю, тем меньше отличается распределение ошибок от нормального распределения.

И последний значимый результат из таблицы 3 – это гетероскедастичность, то есть степень неоднородности данных, которая проявляется в непостоянстве дисперсий случайных ошибок.

Но всё же самая значимая таблица для данного исследования – это таблица 2, поскольку она содержит оценки неизвестных параметров модели, полученные методом максимального правдоподобия. В рассматриваемой модели параметр один, и это дисперсия ошибки, оценка которой: $\hat{\sigma}_{ML} = 2.302 \cdot 10^7$.

Осталось построить график:

```
In [6]: def plot(res_model, title):
        predict = res_model.get_prediction(start='2014-11-01',
                                           end='2015-02-20')
        forecast = res_model.get_forecast('2015-03-20')

        fig, ax = plt.subplots(figsize=(12,6))

        dta.ix['2014-11-01:'].plot(ax=ax, style='k',
                                  label='Observations')
        predict.predicted_mean.plot(ax=ax,
                                    label='One-step-ahead Prediction')

        predict_ci = predict.conf_int(alpha=0.05)
        ax.fill_between(predict_ci.index[2:], predict_ci.iloc[2:, 0],
                        predict_ci.iloc[2:, 1], alpha=0.1,
                        label='95% confidence interval')

        forecast.predicted_mean.plot(ax=ax, style='--',
                                     label='Forecast')
        forecast_ci = forecast.conf_int()
        ax.fill_between(forecast_ci.index, forecast_ci.iloc[:, 0],
                        forecast_ci.iloc[:, 1], alpha=0.1,
                        label='95% confidence interval')

        legend = ax.legend(loc='lower left')
        ax.set_xlabel('Date')
        ax.set_ylabel('Sales')
        title = title + ' results'
        ax.set_title(title)
```

```
In [7]: plot(res_model_1, 'Irregular model')
```




Рис. 3: Прогноз в модели Irregular

На рисунке 3 легко увидеть, что прогноз совсем не соответствует действительности: среднее значение данных сильно отличается от нуля, а значит, модель непригодна для них и нуждается в улучшении.

Информацию из таблиц частично можно наблюдать на графиках, к чему мы и будем прибегать в дальнейшем. Для этой модели анализ остатков (а тут больше ничего и нет) выглядит так:

```
In [8]: res_model_1.plot_diagnostics(figsize=(8,6))
plt.tight_layout()
```




Рис. 4: Анализ остатков в модели Irregular

3.2 Моделирование константой – Deterministic constant

Ещё одна простая модель, в которой наблюдения предполагаются независимыми и одинаково распределёнными случайными величинами равными сумме константы и ошибки:

$$y_t = \mu + \varepsilon_t, \varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2)$$

Сама константа получается из задачи минимизации среднеквадратичной ошибки. Как и в предыдущей модели, наблюдения независимы, поэтому и предсказываемое значение не зависит от предыдущих и задачу можно записать так:

$$\begin{aligned} MSE &= E[(Y_{n+h} - c)^2] = E[Y_{n+h}^2 - 2 \cdot c \cdot Y_{n+h} + c^2] = \\ &= E(Y_{n+h}^2) - 2 \cdot c \cdot E(Y_{n+h}) + c^2 = E(Y_{n+h}^2) - 2 \cdot c \cdot \mu + c^2 \rightarrow \min_c \\ \frac{\partial MSE}{\partial c} &= -2 \cdot \mu + 2 \cdot c \Rightarrow c = \mu \end{aligned}$$

Получили, что искомая константа – это математическое ожидание наблюдений. Значит, прогнозные значения должны быть близки к выборочному среднему в силу большого числа наблюдений. Обучив модель, можем убедиться в этом для значений y_{t+h} , $h \geq 1$:

```
In [9]: print('Выборочное среднее: ', np.mean(dta))
        print('Значение прогноза: ',
              res_model_2.predict(start='2015-02-20').values)
```

Выборочное среднее: 4 759

Значение прогноза: 4 752

Посмотрим, каковы оценки параметров, и визуализируем результат.

	coef	std err	z	P> z	[0.025	0.975]
sigma2.irregular	$1.01 \cdot 10^6$	$4.01 \cdot 10^4$	25.2	0	$9.33 \cdot 10^5$	1.0910^6

Таблица 4: Оценки параметров в константной модели




Рис. 5: Прогноз в константной модели

Каждую из составляющих частей модели тоже можно визуализировать.

```
In [10]: res_model_2.plot_components(figsize=(12, 6))
plt.tight_layout()
```




Рис. 6: Декомпозиция в константной модели

В сравнении с предыдущей моделью прогнозирование константой дало более правдоподобный результат, что видно из рисунка 5: предсказанное значение – это среднее по прошлым наблюдениям. Тем не менее, модель всё ещё не улавливает колебаний вокруг линии средних.

3.3 Модель локального уровня – Local level

Эта модель, в отличие от предыдущих, содержит два параметра, так как в ней тренд μ_t предполагается зависящим от времени и содержащим ошибку η_t . В терминах модели состояние-наблюдение тренд – это состояние, то есть часть, которую мы не наблюдаем, а y_t – напротив, видимые данные, то есть наблюдения.

$$\begin{aligned} y_t &= \mu_t + \varepsilon_t, \varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2) \\ \mu_{t+1} &= \mu_t + \eta_t, \eta_t \sim \mathcal{N}(0, \sigma_\eta^2) \\ \mu_1 &\sim \mathcal{N}(a_1, P_1) \end{aligned}$$

В модели локального уровня распределения случайных величин y_t и μ_t зависят от времени t , и дополнительно предполагается, что в начальный момент времени распределение μ_1 таково: $\mu_1 \sim \mathcal{N}(a_1, P_1)$, где a_1, P_1 , а также $\sigma_\varepsilon^2, \sigma_\eta^2$ известны. Это необходимо, потому что значения ненаблюдаемой переменной μ_t находятся с помощью фильтра Калмана, который позволяет посчитать математическое ожидание и дисперсию ненаблюдаемого состояния с учётом наблюдений. Фильтр Калмана – это рекурсивный алгоритм, и текущая оценка параметров обновляется, как только появляется новое наблюдение, иначе говоря, повторяются два этапа: предсказание и корректировка.

Формальное описание фильтра Калмана следующее:

- $Y_{t-1} = (y_1, \dots, y_{t-1})'$ – вектор наблюдений
- $\mu_t \mid Y_{t-1} \sim \mathcal{N}(a_t, P_t)$ – условное распределение μ_t при известном Y_{t-1} , где a_t, P_t также известны
- $\mu_t \mid Y_t \sim \mathcal{N}(a_{t|t}, P_{t|t})$ – условное распределение μ_t при известном Y_t
- $\mu_{t+1} \mid Y_t \sim \mathcal{N}(a_{t+1}, P_{t+1})$ – условное распределение μ_{t+1} при известном Y_t

Задача – найти $a_{t|t}, P_{t|t}, a_{t+1}$ и P_{t+1} , когда появляется новое наблюдение y_t , где $a_{t|t}$ – оценка фильтра для μ_t , a_{t+1} – прогноз для μ_t на один шаг вперёд, а $P_{t|t}$ и P_{t+1} – соответствующие дисперсии. Также обозначим за $v_t = y_t - a_t$ величину ошибки прогноза.

Пользуясь нормальностью распределений, можно показать¹, что

$$\begin{aligned} a_{t|t} &= a_t + \frac{P_t}{P_t + \sigma_\varepsilon^2} v_t & a_{t+1} &= a_t + \frac{P_t}{P_t + \sigma_\varepsilon^2} v_t \\ P_{t|t} &= \frac{P_t \sigma_\varepsilon^2}{P_t + \sigma_\varepsilon^2} & P_{t+1} &= \frac{P_t \sigma_\varepsilon^2}{P_t + \sigma_\varepsilon^2} + \sigma_\eta^2 \end{aligned}$$

Далее необходимо посчитать дисперсию ошибки прогноза: $F_t = \text{Var}(v_t) = P_t + \sigma_\varepsilon^2$, и усиление Калмана: $K_t = P_t/F_t$, после чего прогноз обновляется.

Все шаги обновления:

$$\begin{aligned} v_t &= y_t - a_t & F_t &= P_t + \sigma_\varepsilon^2 \\ a_{t|t} &= a_t + K_t v_t & P_{t|t} &= P_t(1 - K_t) \\ a_{t+1} &= a_t + K_t v_t & P_{t+1} &= P_t(1 - K_t) + \sigma_\eta^2 \end{aligned}$$

Оценки параметров будут следующими:

	coef	std err	z	P> z	[0.025	0.975]
sigma2.irregular	$1.31 \cdot 10^5$	$1.61 \cdot 10^4$	8.17	0	$9.97 \cdot 10^4$	$1.63 \cdot 10^5$
sigma2.level	$3.91 \cdot 10^5$	$3.08 \cdot 10^4$	12.7	0	$3.30 \cdot 10^5$	$4.51 \cdot 10^5$

Таблица 5: Оценки параметров в модели локального уровня

Наглядные же результаты модели таковы:

¹Подробный вывод соотношений содержится в [3] на стр. 11




Рис. 7: Прогноз в модели локального уровня




Рис. 8: Декомпозиция в модели локального уровня

Пока модель локального уровня даёт самый точный прогноз на исходных данных. Можно заметить, что он похож на наблюдения, сдвинутые на один период вперёд. Это объясняется тем, что уровень моделируется случайным блужданием, о котором будет сказано далее. Что касается прогноза на будущее, то в модели локального уровня он равен последнему известному значению, что также объясняется в следующем разделе.

3.4 Случайное блуждание – Random walk

В модели случайного блуждания каждое следующее значение предполагается равным сумме предыдущего значения и ошибки.

$$y_t = \mu_t$$

$$\mu_t = \mu_{t-1} + \eta_t, \eta_t \sim \mathcal{N}(0, \sigma_\eta^2)$$

При прогнозе на известных наблюдениях на один шаг вперёд получится этот же исходный ряд, но с лагом в один период, а прогнозирование на большее количество шагов вперёд будет равно последнему известному значению. Чтобы доказать это, нужно взять условное математическое ожидание от прогнозируемого значения при всех известных предыдущих значениях. Для μ_{t+k} и для любого $k \in \mathbb{N}$ уравнение ненаблюдаемой компоненты можно привести к виду $\mu_{t+k} = \mu_t + \sum_{i=2}^{k+1} \eta_i$, последовательно подставляя выражения для μ_i до первого известного. Тогда прогноз будет таким:

$$\hat{\mu}_{t+k} = E \left(\mu_t + \sum_{i=2}^{k+1} \eta_i \mid \mu_t, \mu_{t-1} \dots \right) = E (\mu_t \mid \mu_t, \mu_{t-1} \dots) = \mu_t$$

что и есть последнее известное значение.

	coef	std err	z	P> z	[0.025	0.975]
sigma2.level	$6.45 \cdot 10^5$	$1.43 \cdot 10^4$	45	0	$6.17 \cdot 10^5$	$6.73 \cdot 10^5$

Таблица 6: Оценки параметров в модели случайного блуждания

Действительно, на рисунке 9 видно, что каждое спрогнозированное значение равно последнему известному. Другими словами, на исходных данных прогноз – это сами




Рис. 9: Прогноз модели случайного блуждания




Рис. 10: Декомпозиция в модели случайного блуждания

данные с единичным лагом, а когда новые наблюдения заканчиваются, каждое прогнозируемое значение — это последнее известное наблюдение. Таким образом, прогноз выходит довольно точным при прогнозировании на один шаг вперёд, и менее точным, но всё же вполне разумным, при прогнозировании на более длительный период, в котором наблюдений нет.

Также можно заметить, что прогноз довольно похож на прогноз в модели локального уровня. Единственное отличие в графиках — доверительный интервал: в модели случайного блуждания он расширяется сильнее.

Чтобы построить доверительный интервал, сначала необходимо найти дисперсию оценки $\hat{\mu}_{t+k}$. В описании модели уравнение уровня было определено рекурсивно. Положим некоторое значение μ_1 известным, тогда значение уровня в момент t можно записать в виде: $\mu_t = \mu_1 + \sum_{j=0}^{t-1} \eta_{t-j}$, и дисперсия оценки:

$$\text{Var}(\hat{\mu}_{t+k}) = \text{Var}(\mu_t) = \text{Var}\left(\mu_1 + \sum_{j=0}^{t-1} \eta_{t-j}\right) = t \cdot \sigma_\eta^2$$

Таким образом, получаем доверительный интервал для значения прогноза на уровне значимости 5%:

$$\hat{\mu}_{t+k} - 1.96\sqrt{t \cdot \sigma_\eta^2} \leq \mu_{t+k} \leq \hat{\mu}_{t+k} + 1.96\sqrt{t \cdot \sigma_\eta^2}$$

Подставляя значение σ_η^2 из таблицы 6, и значения прогноза, получим в точности доверительный интервал, который изображён на рисунке, в чём можно убедиться с помощью функции `model.fit().get_forecast(DATE).conf_int()`.

В общем случае, когда уравнение на y_t содержит большее число компонент, необходимо также найти дисперсию оценки для \hat{y}_{t+h} и подставить в доверительный интервал вида:

$$\hat{y}_{t+h} - 1.96\sqrt{\text{Var}(\hat{y}_{t+h})} \leq y_{t+h} \leq \hat{y}_{t+h} + 1.96\sqrt{\text{Var}(\hat{y}_{t+h})}$$

Проделав то же самое для предыдущей модели — модели локального уровня, полу-

чим, что $\text{Var}(\hat{y}_{t+h}) = t \cdot \sigma_{\eta}^2 + \sigma_{\varepsilon}^2 + 2 \text{Cov}(\sigma_{\eta}^2, \sigma_{\varepsilon}^2)$ и значение дисперсии, действительно, будет меньше для каждого значения прогноза.

3.5 Постоянный тренд – Deterministic trend

В этой модели задаётся линейный тренд:

$$y_t = \mu_t + \varepsilon_t, \varepsilon_t \sim \mathcal{N}(0, \sigma_{\varepsilon}^2)$$

$$\mu_t = \mu_{t-1} + \beta$$

И переменная, отвечающая за тренд, меняется на константу каждый период, покажем:

$$y_t = \mu_{t-1} + \beta + \varepsilon_t$$

$$y_{t-1} = \mu_{t-2} + \beta + \varepsilon_{t-1}$$

$$\begin{aligned} E(y_t - y_{t-1}) &= E[(\mu_{t-1} + \beta + \varepsilon_t) - (\mu_{t-2} + \beta + \varepsilon_{t-1})] = E(\mu_{t-1} + \varepsilon_t - \mu_{t-2} - \varepsilon_{t-1}) = \\ &= E(\mu_{t-2} + \beta - \mu_{t-2}) + E(\varepsilon_t) - E(\varepsilon_{t-1}) = \beta \end{aligned}$$

	coef	std err	z	P> z	[0.025	0.975]
sigma2.irregular	$1.00 \cdot 10^6$	$3.62 \cdot 10^4$	27.7	0	$9.31 \cdot 10^5$	$1.07 \cdot 10^6$
$\hat{\beta}_{t+h}$	-0.47					

Таблица 7: Оценки параметров в модели постоянного тренда




Рис. 11: Прогноз в модели постоянного тренда




Рис. 12: Декомпозиция в модели постоянного тренда

Несмотря на то, что в этой модели тренд задаётся линейно, качество её сопоставимо с константной моделью, поскольку явно выраженного тренда в данных не видно и модель также не улавливает колебания.

3.6 Локальный линейный постоянный тренд – Local linear deterministic trend

Отличие этой модели от предыдущей только в добавлении ошибки η_t в тренд:

$$y_t = \mu_t + \varepsilon_t, \varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2)$$

$$\mu_t = \mu_{t-1} + \beta + \eta_t, \eta_t \sim \mathcal{N}(0, \sigma_\eta^2)$$

Однако прогноз на известных данных больше напоминает результаты модели случайного блуждания: предыдущее известное значение + ошибка прогноза, смещённое на фиксированную величину. Прогноз неизвестных значений отличается от каждого предыдущего на константу β – рассуждения такие же, как и в предыдущей модели. Тем не менее, из-за добавленной ошибки доверительный интервал будет расширяться со временем.

	coef	std err	z	P> z	[0.025	0.975]
sigma2.irregular	$1.29 \cdot 10^5$	$1.62 \cdot 10^4$	7.99	0	$9.76 \cdot 10^4$	$1.61 \cdot 10^5$
sigma2.level	$3.94 \cdot 10^5$	$3.13 \cdot 10^4$	12.6	0	$3.33 \cdot 10^5$	$4.56 \cdot 10^5$
$\hat{\beta}_{t+h}$	0.52					

Таблица 8: оценки параметров в модели локального линейного постоянного тренда




Рис. 13: Прогноз в модели локального линейного постоянного тренда




Рис. 14: Декомпозиция в модели локального линейного постоянного тренда

Результат модели снова напоминает прогнозы в моделях локального уровня и случайного блуждания, что неудивительно, поскольку единственное отличие первой от локального линейного постоянного тренда в отсутствии константы в уравнении уровня, которая превращает его в уравнение модели случайного блуждания со смещением.

3.7 Случайное блуждание со смещением – Random walk with drift

Модель случайного блуждания со смещением записывается следующим образом:

$$y_t = \mu_t$$

$$\mu_t = \mu_{t-1} + \beta + \eta_t, \eta_t \sim \mathcal{N}(0, \sigma_\eta^2)$$

Если предположить начальное значение $\mu_0 = a$ известным, то модель можно записать в виде: $\mu_t = a + t \cdot \beta + \sum_{j=0}^{t-1} \eta_{t-j}$. Найдём математическое ожидание и дисперсию:

$$E(\mu_t) = E(y_t) = t \cdot \beta \rightarrow \infty$$

$$Var(\mu_t) = Var(y_t) = t \cdot \sigma_\eta^2 \rightarrow \infty$$

что объясняет вид графика с прогнозом: прогнозируемые значения – это прямая с постоянным наклоном, а доверительный интервал расширяется со временем.

	coef	std err	z	P> z	[0.025	0.975]
sigma2.level	$6.46 \cdot 10^5$	$1.44 \cdot 10^4$	44.9	0	$6.18 \cdot 10^5$	$6.74 \cdot 10^5$
$\hat{\beta}_{t+h}$	-0.34					

Таблица 9: Оценки параметров в модели случайного блуждания со смещением




Рис 15: Прогноз в модели случайного блуждания со смещением




Рис. 16: Декомпозиция в модели случайного блуждания со смещением

Прогноз снова знакомый: он мало отличается от обычного случайного блуждания и локального уровня. Разница в доверительных интервалах обусловлена различием в оценке параметра σ_η^2 .

3.8 Локальный линейный тренд – Local linear trend

В этой модели добавляется ещё одна случайная компонента: наклон тренда β , значения которого моделируются случайным блужданием.

$$\begin{aligned}y_t &= \mu_t + \varepsilon_t, \varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2) \\ \mu_t &= \mu_{t-1} + \beta_{t-1} + \eta_t, \eta_t \sim \mathcal{N}(0, \sigma_\eta^2) \\ \beta_t &= \beta_{t-1} + \zeta_t, \zeta_t \sim \mathcal{N}(0, \sigma_\zeta^2)\end{aligned}$$

Или она же, но в форме модели состояние-наблюдение:

$$\begin{aligned}y_t &= \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \varepsilon_t \\ \begin{pmatrix} \mu_{t+1} \\ \beta_{t+1} \end{pmatrix} &= \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \begin{pmatrix} \eta_t \\ \zeta_t \end{pmatrix}\end{aligned}$$

В модели остается только найти ковариационные матрицы:

$$\begin{aligned}H_t &= \begin{bmatrix} \sigma_\varepsilon^2 \end{bmatrix} \\ Q_t &= \begin{bmatrix} \sigma_\eta^2 & 0 \\ 0 & \sigma_\zeta^2 \end{bmatrix}\end{aligned}$$

	coef	std err	z	P> z	[0.025	0.975]
sigma2.irregular	$1.30 \cdot 10^5$	$1.68 \cdot 10^4$	7.74	0	$9.68 \cdot 10^4$	$1.62 \cdot 10^5$
sigma2.level	$3.96 \cdot 10^5$	$3.15 \cdot 10^4$	12.6	0	$3.34 \cdot 10^5$	$4.57 \cdot 10^5$
sigma2.trend	$0.04 \cdot 10^{-2}$	63.8	$6.26 \cdot 10^{-6}$	1	-125	125

Таблица 10: Оценки параметров в модели локального линейного тренда




Рис. 17: Прогноз в модели локального линейного тренда




Рис. 18: Декомпозиция в модели локального линейного тренда

Качественного нового прогноза снова не получилось. Более того, заметим, что оценка ошибки в уравнении тренда очень мала, то есть тренд в этой модели – почти константа. А другие оценки очень близки к тем, что были получены в модели локального уровня, отсюда и большое сходство.

3.9 Сглаженный тренд – Smoothed trend

Отличие этой модели от предыдущей в том, что в уравнении, задающем тренд, отсутствует компонента ошибки η_t , отчего модель получила название ”сглаженный тренд”. Сам же тренд по-прежнему моделируется случайным блужданием.

$$y_t = \mu_t + \varepsilon_t, \varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2)$$

$$\mu_t = \mu_{t-1} + \beta_{t-1}$$

$$\beta_t = \beta_{t-1} + \zeta_t, \zeta_t \sim \mathcal{N}(0, \sigma_\zeta^2)$$

	coef	std err	z	P> z	[0.025	0.975]
sigma2.irregular	$2.98 \cdot 10^5$	$1.09 \cdot 10^4$	27.2	0	$2.77 \cdot 10^5$	$3.19 \cdot 10^5$
sigma2.trend	$8.25 \cdot 10^4$	7917	10.4	0	$6.70 \cdot 10^4$	$9.80 \cdot 10^4$

Таблица 11: Оценки параметров в модели сглаженного тренда




Рис. 19: Прогноз в модели сглаженного тренда




Рис. 20: Декомпозиция в модели сглаженного тренда

На рисунке 19 видно, что доверительный интервал выглядит совсем не так, как в предыдущих моделях. Попробуем определить его вид аналитически. Для это сначала сведём все уравнения в одно. Так, уравнение наклона моделируется случайным блужданием представимо в виде $\beta_t = \beta_1 + \sum_{j=0}^{t-1} \zeta_j$. Подставим полученное в уравнение уровня: $\mu_{t+1} = \mu_t + \beta_1 + \sum_{j=0}^{t-1} \zeta_j$. Тогда уравнение наблюдений примет вид:

$$y_{t+1} = \mu_1 + t\beta_1 + t \sum_{j=0}^{t-1} \zeta_j + \varepsilon_t$$

А дисперсия прогноза будет равна:

$$\text{Var}(\hat{y}_{t+h}) = t^2 \sigma_\zeta^2 + \sigma_\varepsilon^2$$

Тогда и доверительный интервал будет расширяться не пропорционально \sqrt{t} , как было в моделях до этого, а пропорционально t , то есть с большей скоростью.

3.10 Случайный тренд – Random trend

В этой модели отсутствует ещё одна переменная, та, что отвечает за погрешность наблюдения, ε_t . В таком случае наблюдения моделируются предыдущими значением тренда и шумовым значением из уравнения, задающего наклон.

$$y_t = \mu_t$$

$$\mu_t = \mu_{t-1} + \beta_{t-1}$$

$$\beta_t = \beta_{t-1} + \zeta_t, \zeta_t \sim \mathcal{N}(0, \sigma_\zeta^2)$$

	coef	std err	z	P> z	[0.025	0.975]
sigma2.trend	$1.53 \cdot 10^6$	$3.15 \cdot 10^4$	48.6	0	$1.47 \cdot 10^6$	$1.59 \cdot 10^6$

Таблица 12: Оценки параметров в модели случайного тренда




Рис. 21: Прогноз в модели случайного тренда




Рис. 22: Декомпозиция в модели случайного тренда

Прогноз в модели случайного тренда визуально похож на результат в предыдущей модели. Дисперсия оценки прогноза здесь будет такой: $\text{Var}(\hat{y}_{t+h}) = t^2 \sigma_\zeta$. Тем не менее можно также заметить, что оценка σ_ζ превосходит соответствующую оценки в модели сглаженного тренда приблизительно в 4 раза. Это, а также отсутствие ошибки σ_ε , объясняет различия в ширине доверительных интервалов.

3.11 Локальный линейный тренд с сезонностью

В данной модели добавляется качественно новый компонент: сезонность, что позволяет учитывать колебания, повторяющиеся с некоторой фиксированной периодичностью.

$$\begin{aligned}
y_t &= \mu_t + \gamma_t + \varepsilon_t, \varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2) \\
\mu_t &= \mu_{t-1} + \beta_{t-1} + \eta_t, \eta_t \sim \mathcal{N}(0, \sigma_\eta^2) \\
\beta_t &= \beta_{t-1} + \zeta_t, \zeta_t \sim \mathcal{N}(0, \sigma_\zeta^2) \\
\mu_1 &\sim \mathcal{N}(a_1, P_1) \\
\gamma_t &= - \sum_{j=1}^{s-1} \gamma_{t+1-j} + \omega_t, \omega_t \sim \mathcal{N}(0, \sigma_\omega^2), s - \text{периодичность}
\end{aligned}$$

По определению, детерминистическая сезонность с периодичностью s – это последовательность чисел, которые повторяются каждые s последовательных наблюдений: $\gamma_t = \gamma_{t-s}$. Более того, сумма их значений равна нулю через s последовательных наблюдений, поскольку в данных за весь год сезонности нет: $\sum_{j=0}^{s-1} \gamma_{t-j} = 0$. Таким образом, детерминистическая сезонность – это периодическая функция с нулевым средним значением, и при известных первых s значениях (которые должны давать в сумме ноль), можно получить все остальные значения с помощью рекурсии: $\gamma_t = - \sum_{j=1}^{s-1} \gamma_{t-j}$. А для того чтобы компонента могла изменяться с течением времени, необходимо добавить случайный шок ω_t .

Зададим годовую сезонность, передав в описание модели параметр `seasonal=12`. Заметим также, что модель с сезонностью наиболее точно улавливает наблюдения среди всех рассмотренных в этой работе моделей: её показатели AIC, BIC и HQIC наименьшие. Тем не менее на рисунке 26 видно, что остатки в модели не полностью соответствуют нормальному распределению.

	coef	std err	z	P> z	[0.025	0.975]
sigma2.irregular	$1.36 \cdot 10^5$	$1.71 \cdot 10^4$	7.93	0	$1.02 \cdot 10^5$	$1.69 \cdot 10^5$
sigma2.level	$3.36 \cdot 10^5$	$2.86 \cdot 10^4$	11.8	0	$2.80 \cdot 10^5$	$3.92 \cdot 10^5$
sigma2.trend	$1.82 \cdot 10^{-6}$	45.8	$3.97 \cdot 10^{-8}$	1	-89.9	89.9
sigma2.seasonal	1014	504	2.01	0.04	25.8	2002

Таблица 13: Оценки параметров в модели с сезонностью

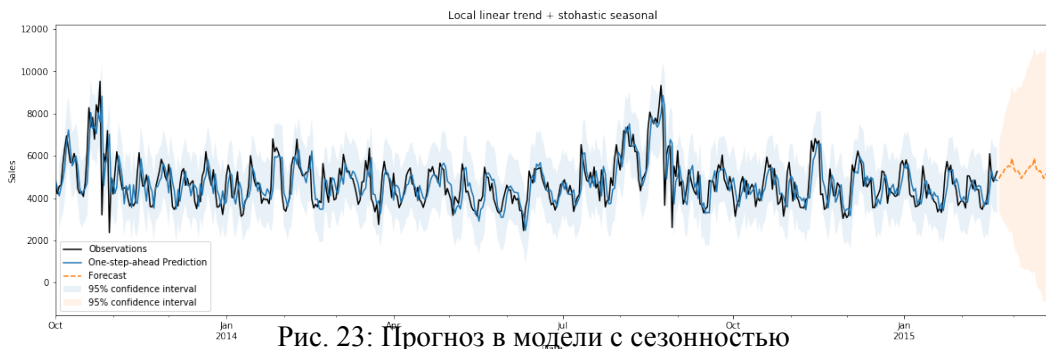


Рис. 23: Прогноз в модели с сезонностью

На рисунке 23 видно, что на исходных данных модель даёт довольно точный прогноз и учитывает как недельные колебания, так и годовые. Однако прогноз вперёд на рисунке 24 уже не отражает годовых колебаний. Заметим, что несмотря на то, что в модели была задана годовая сезонность, колебания компоненты, отвечающей за это, соответствуют недельным. Ежегодный рост продаж в ноябре и декабре отражён в компоненте уровня, но тем не менее, это не улучшило долгосрочный прогноз.




Рис.24: Прогноз в модели с сезонностью




Рис. 25: Декомпозиция в модели с сезонностью

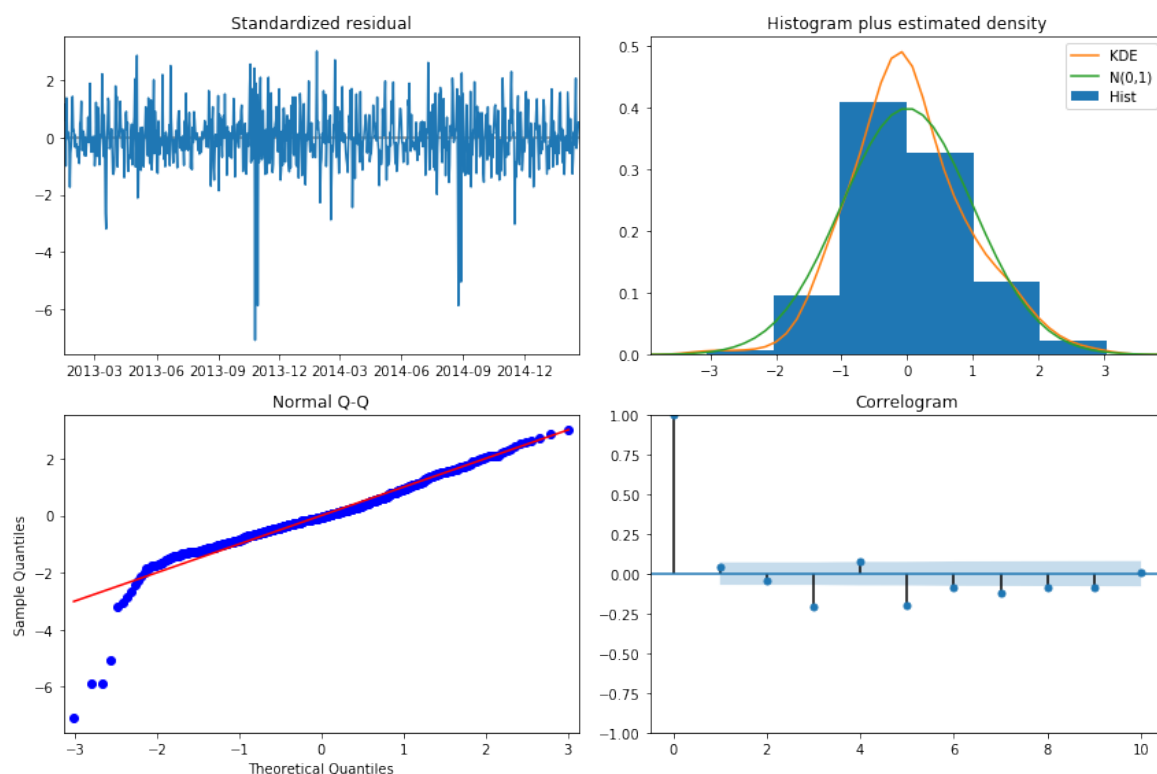


Рис. 26: Анализ остатков в модели с сезонностью

3.12 Локальный линейный тренд с сезонностью и регрессорами

Предыдущую версию модели можно уточнить, добавив наблюдаемый объясняющие переменные, или регрессоры. Добавив их в уравнение, связывающее наблюдения с ненаблюдаемыми компонентами, получим статическую регрессию (как в данном случае), а при добавлении регрессора в одно из уравнений ненаблюдаемой компоненты – динамическую. Например, если определить μ_t как $\mu_t = \mu_{t-1} + \beta_{t-1} + \delta^T x_t + \eta_t$, то получим, что μ_{t+1} зависит от μ_t , которая в свою очередь зависит от x_t . Эти рассуждения верны и для $t+2, t+3, \dots$. Таким образом, регрессор, относящийся к моменту времени t влияет на настоящее и будущее значение μ , а следовательно, и на все соответствующие значения y_t .

Но мы рассмотрим статическую регрессию с двумя регрессорами, которая записывается следующим образом:

$$\begin{aligned}y_t &= \mu_t + \gamma_t + \delta_1^T x_t + \delta_2^T z_t + \varepsilon_t, \varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2) \\ \mu_t &= \mu_{t-1} + \beta_{t-1} + \eta_t, \eta_t \sim \mathcal{N}(0, \sigma_\eta^2) \\ \beta_t &= \beta_{t-1} + \zeta_t, \zeta_t \sim \mathcal{N}(0, \sigma_\zeta^2) \\ \mu_1 &\sim \mathcal{N}(a_1, P_1) \\ \gamma_t &= - \sum_{j=1}^{s-1} \gamma_{t+1-j} + \omega_t, \omega_t \sim \mathcal{N}(0, \sigma_\omega^2)\end{aligned}$$

Значения x_t положим равными единице, если день t – воскресенье, и нулю иначе, а z_t будут единицами только в случае праздника в день t

```
In
[11]: data['isSunday'] = (data.DayOfWeek==7).astype('int')
      data['isHoliday'] = (data['StateHoliday']=='a').astype('int')
      sd_dta = data[data.Store==1][['Sales', 'isSunday',
                                     'isHoliday']].sort_index()
```

Обучаем модель, добавляя регрессоры в описание параметров:

```
In
[12]: model_12_1 = statsmodels.tsa.statespace.structural.Unobserved\
      Components(endog=sd_dta['Sales'], level='lltrend',
                  trend=True, seasonal=12, cycle=False,
                  autoregressive=None,
                  exog=sd_dta[['isSunday', 'isHoliday']],
                  irregular=True, stochastic_level=True,
                  stochastic_trend=True,
                  stochastic_seasonal=True,
                  stochastic_cycle=False,
                  damped_cycle=False,
                  cycle_period_bounds=None)
```

	coef	std err	z	P> z	[0.025	0.975]
sigma2.irregular	$5.56 \cdot 10^5$	$1.80 \cdot 10^4$	30.9	0	$5.21 \cdot 10^5$	$5.92 \cdot 10^5$
sigma2.level	$1.89 \cdot 10^5$	$1.45 \cdot 10^4$	13.1	0	$1.61 \cdot 10^5$	$2.17 \cdot 10^5$
sigma2.trend	$7.91 \cdot 10^{-5}$	16.7	$4.75 \cdot 10^{-6}$	1	-32.7	32.7
sigma2.seasonal	0,01	154	$7.30 \cdot 10^{-5}$	1	-302	302
beta.isSunday	-4768	89.2	-53.5	0	-4942	-4593
beta.isHoliday	-5030	313	-16.1	0	-5644	-4417

Таблица 14: Оценки параметров для модели с регрессорами

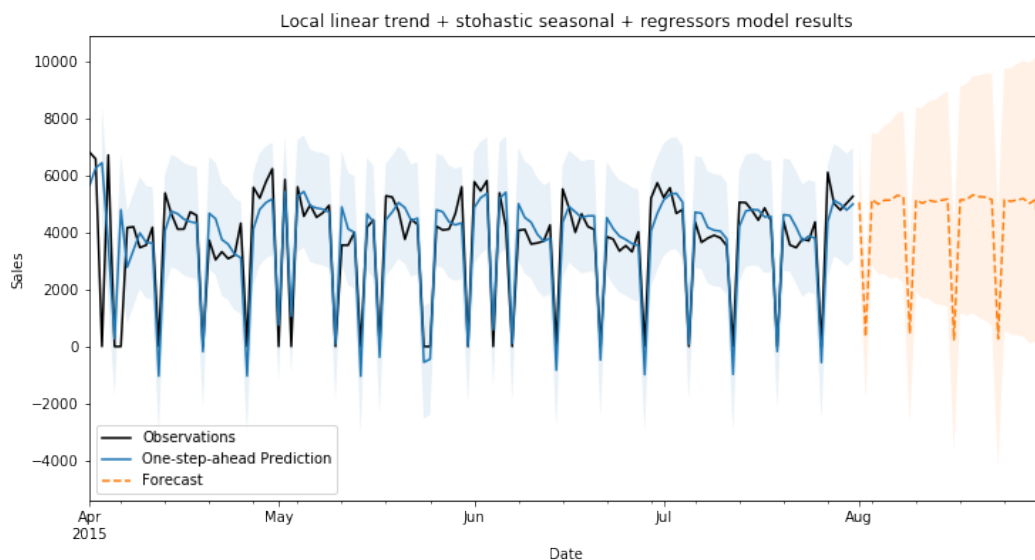


Рис. 27: Прогноз в модели с регрессорами




Рис. 28: Декомпозиция в модели с регрессорами

По рисунку 27 видно, что модель прогнозирует даже отрицательные продажи, когда магазин закрыт, другими словами, она очень неустойчива к выбросам. Так что, если задаться целью прогнозировать максимально точно, стоит обучаться на данных с ненулевыми значениями и восстанавливать их потом. Также стоит отметить, что модель унаследовала недостатки предшествующей и не уловила годовой сезонности.

4 Построение модели многомерных рядов

Модели, описанные в предыдущей главе, могут быть обобщены для многомерного случая, когда нужно одновременно анализировать p временных рядов. В частности, в данных, которые я использовала, содержалась информация о продажах в более чем ста магазинах сети, и для каждого такого ряда необходимо сделать прогноз.

4.1 Описание модели

Модель состояние-наблюдения для нескольких временных рядов записывается следующим образом:

$$y_t = Z_t \alpha_t + \varepsilon_t \quad \varepsilon_t \sim \mathcal{N}(0, H_t) \quad (1)$$

$$\alpha_{t+1} = T_t \alpha_t + R_t \eta_t \quad \eta_t \sim \mathcal{N}(0, Q_t) \quad (2)$$

для $t = 1, 2, \dots$. Уравнение наблюдений y_t — это вектор размера $p \times 1$, который содержит значения всех p временных рядов в момент времени t . Вектор ε_t размерности $p \times 1$ содержит все шумы для соответствующих временных рядов. Эти ошибки распределены нормально с нулевым математическим ожиданием и ковариационной матрицей H_t размерности $p \times p$.

Вектор $m \times 1$ состояний α_t содержит все ненаблюдаемые компоненты и неизвестные постоянные значения. Матрица Z_t , размерность которой $p \times m$ связывает эти компоненты и регрессоры с вектором наблюдений. Матрица T_t — называется матрицей перехода и имеет размерность $m \times m$. Вектор $r \times 1$ η_t содержит шумы, которые распределены нормально с нулевым математическим ожиданием и ковариационной матрицей Q_t , $r \times r$. Часто $r = m$ и матрица R_t — это единичная матрица I_m . Но поскольку R_t задаётся произвольно, то её размерность может быть $m \times r$, где $r < m$.

4.2 Пример: модель локального линейного уровня с регрессорами

Запишем модель локального линейного уровня в форме состояние-наблюдение для двух временных рядов ($p = 2$). Выпишем все вектора и матрицы:

$$\alpha_t = \begin{pmatrix} \mu_t^{(1)} \\ \nu_t^{(1)} \\ \beta_t^{(1)} \\ \mu_t^{(2)} \\ \nu_t^{(2)} \\ \beta_t^{(2)} \end{pmatrix} \quad \eta_t = \begin{pmatrix} \xi_t^{(1)} \\ \zeta_t^{(1)} \\ \xi_t^{(2)} \\ \zeta_t^{(2)} \end{pmatrix} \quad T_t = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad R_t = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

$$Z_t = \begin{bmatrix} 1 & 0 & x_t & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & x_t \end{bmatrix} \quad H_t = \begin{bmatrix} \sigma_{\varepsilon^{(1)}}^2 & \text{cov}(\varepsilon^{(1)}, \varepsilon^{(2)}) \\ \text{cov}(\varepsilon^{(1)}, \varepsilon^{(2)}) & \sigma_{\varepsilon^{(2)}}^2 \end{bmatrix}$$

$$Q_t = \begin{bmatrix} \sigma_{\xi^{(1)}}^2 & 0 & \text{cov}(\xi^{(1)}, \xi^{(2)}) & 0 \\ 0 & \sigma_{\zeta^{(1)}}^2 & 0 & \text{cov}(\zeta^{(1)}, \zeta^{(2)}) \\ \text{cov}(\xi^{(1)}, \xi^{(2)}) & 0 & \sigma_{\xi^{(2)}}^2 & 0 \\ 0 & \text{cov}(\zeta^{(1)}, \zeta^{(2)}) & 0 & \sigma_{\zeta^{(2)}}^2 \end{bmatrix}$$

В данном случае регрессор x_t применяется к обоим рядам. Надстрочные индексы (1) и (2) выделяют компоненты, относящиеся к первому и второму ряду соответственно.

Уравнения для наблюдений можно получить, подставив соответствующие матрицы в уравнение 1:

$$\begin{aligned} y_t^{(1)} &= \mu_t^{(1)} + \beta_t^{(1)} + x_t + \varepsilon_t^{(1)} \\ y_t^{(2)} &= \mu_t^{(2)} + \beta_t^{(2)} + x_t + \varepsilon_t^{(2)} \end{aligned}$$

Аналогично для уравнений, задающих состояния, из уравнения 2 получим:

$$\begin{aligned} \mu_{t+1}^{(1)} &= \mu_t^{(1)} + \nu_t^{(1)} + \xi_t^{(1)} \\ \nu_{t+1}^{(1)} &= \nu_t^{(1)} + \zeta_t^{(1)} \\ \beta_{t+1}^{(1)} &= \beta_t^{(1)} \\ \mu_{t+1}^{(2)} &= \mu_t^{(2)} + \nu_t^{(2)} + \xi_t^{(2)} \\ \nu_{t+1}^{(2)} &= \nu_t^{(2)} + \zeta_t^{(2)} \\ \beta_{t+1}^{(2)} &= \beta_t^{(2)} \end{aligned}$$

4.3 Общие уровни и наклоны

В случае многомерных временных рядов уравнения наблюдений и состояний включают в себя ошибки, относящиеся к определённым компонентам. Например, $\zeta_t^{(1)}$ и $\zeta_t^{(2)}$ связаны с наклонами $\nu_t^{(1)}$ и $\nu_t^{(2)}$. Когда эти ошибки не коррелированы, наклоны не зависимы. И, наоборот, зависимы, когда $\text{cov}(\zeta^{(1)}, \zeta^{(2)}) \neq 0$. Модели многомерных временных рядов, которые содержат векторы ненаблюдаемых компонент, зависящих от коррелирующих ошибок, называются *по-видимому несвязанными уравнениями временных рядов* (*seemingly unrelated time series equations*), то есть подразумевается, что уравнения независимы, несмотря на то что ошибки могут быть коррелированы.

Степень зависимости измеряется коэффициентом корреляции между ошибками. В случае $-1 < \text{corr}(\zeta^{(1)}, \zeta^{(2)}) < 1$ ранг матрицы

$$\begin{bmatrix} \sigma_{\zeta^{(1)}}^2 & \text{cov}(\zeta^{(1)}, \zeta^{(2)}) \\ \text{cov}(\zeta^{(1)}, \zeta^{(2)}) & \sigma_{\zeta^{(2)}}^2 \end{bmatrix}$$

равен двум. Когда же $\text{corr}(\zeta^{(1)}, \zeta^{(2)}) = \pm 1$, ранг равен единице.

Таким образом, исходя из информации о ранге ковариационной матрицы, можно сделать вывод, являются ли компоненты рядов общими, что важно, поскольку даёт дополнительную информацию о взаимосвязях между временными рядами.

5 Заключение

В работе описан ряд одномерных моделей с ненаблюдаемыми компонентами, для каждой из которых представлен прогноз на реальных данных и объяснение вида прогноза. Оказалось, что лучше всех моделей исходные данные объясняет модель локального линейного тренда с сезонностью. Модели локального линейного тренда без сезонной компоненты, модель локального линейного постоянного тренда и локального уровня показали приблизительно одинаковые результаты и также позволили получить неплохой прогноз. В работе содержится код на языке Python, позволяющий воспроизвести полученные результаты.

В исследовании также разобрана модель для многомерных временных рядов, указаны её особенности, приведён пример для случая двух временных рядов.

Работа может быть дополнена за счёт написания кода для моделирования многомерных временных рядов, так как в открытых источниках подробного объяснения процедуры написания таких моделей нет. Также направлением для развития исследования видится использование байесовского подхода к оценке параметров: было бы интересно сравнить эти результаты с результатами, полученными в рамках классического подхода.

6 Список источников

- [1] Brockwell, P. J. and R. A. Davis (2002). Introduction to Time Series and Forecasting (2nd edition). Springer. pp. 1–40.
- [2] Commandeur, J. J. F. and S. J. Koopman (2007). An Introduction to State Space Time Series Analysis. Oxford University Press.
- [3] Durbin, J. and S. J. Koopman (2001). Time Series Analysis by State Space Methods. Oxford University Press. pp. 9–16, 43–52.
- [4] Pelagatti, M. M. (2016). Time Series Modelling with Unobserved Components. CRC Press.